

# Využití hlubokých neuronových sítí pro segmentaci parenchymatózních orgánů břišní dutiny prasete domácího


Bohdan Yeremenko<sup>1</sup>

## 1 Úvod


S vývojem neuronových sítí roste možnost jejich využití při zpracování složitých problémů. Oblast zpracování biomedicínských dat vyžaduje vysokou kvalitu a adaptaci k dostupným datovým sadám. Výzkumy, které byly úspěšné v této oblasti, často využívají data adaptovaná na lidské jedince. Kvůli etickým omezením není však povoleno provádět experimenty přímo na lidech. Proto je stále nutné modifikovat a testovat dnešní technologie na datových sadách odpovídajících zvířatům, na kterých lékaři provádějí své experimenty pro vývoj medicíny. Pokud se rozhodneme použít neuronovou síť pro práci s experimentálními daty, často se setkáváme s nedostatkem dat pro správné nastavení funkčního 3D datasetu pro trénování neuronové sítě, jako je U-Net. Z toho důvodu jsme se pokusili tento problém vyřešit pomocí frameworku "detectron2", který je vyvinut na architektuře konvoluční Mask-RCNN, a zhodnotit jeho schopnost segmentovat orgány.

## 2 Zpracování dat pro neuronovou síť

Původní data jsme získali ve spolupráci s biomedicínským centrem v Plzni, které se specializuje na výzkum rakoviny jater a provádí experimenty na domácích prasatech. Data jsme získali ve formátu DICOM pomocí výpočetního tomografu (CT), který měří data přímo na subjektech experimentu. Pro naši studii jsme potřebovali 2D dataset, proto jsme museli původní 3D objekty rozdělit podle řezů, které tomograf používá k vytvoření svého výstupu. V rámci předchozího výzkumu centra NTIS jsme již měli knihovnu v jazyce Python, která umí pracovat s formátem DICOM, a pomocí ní jsme převedli náš dataset do vhodného formátu souborů PNG. Samostatně jsme provedli anotaci na základě příkladu poskytnutého lékařem. Pro tento úkol jsme zapojili další studenty v rámci univerzitního projektu, neboť výsledné masky budou rovněž využity pro další výzkum. Výsledné anotace jsme získali ve formátu JSON spolu s odpovídajícím souborem PNG.



(a) Řez 657 pacienta 37




(b) Výsledná anotace řezu (a)

**Obrázek 1:** Zobrazení výsledků anotace na příkladu jednoho řezu.

<sup>1</sup> student bakalářského (navazujícího) studijního programu Aplikované vědy a informatika, obor Kybernetika a řídicí technika, e-mail: bohdany@students.zcu.cz

### 3 Použití datasetu pro trénování

Cílem našeho experimentu bylo sledovat dynamiku výsledků během trénování a analyzovat faktory ovlivňující hodnotu IoU. Pro tento účel jsme postupně zvyšovali počet iterací a hodnotu learning rate (LR). Výběr konkrétních hodnot iterací (300, 900, 1500, 3000) a LR (0,01, 0,001, 0,0001, 0,00001) nám umožnil sledovat a porovnávat výsledky v různých fázích trénování. Použili jsme metodu Intersection over Union (IoU) k vyhodnocování výsledků segmentace. Výsledky jsme reprezentovali binárně, kde hodnota 1 značila přítomnost orgánu a hodnota 0 označovala pozadí. Tím jsme získali informace o správnosti segmentace v jednotlivých pixelech. Z našich experimentů jsme zjistili, že nejlepší dynamiku trénování jsme dosahovali při learning rate (LR) rovném 0,001. Tuto hodnotu jsme zvolili jako konstantní pro další experimenty. Dalším zjištěním bylo, že hodnota IoU při hodnocení celého pacienta je významně ovlivněna absencí segmentovaných orgánů v některých řezech. To jsme brali v úvahu při vyhodnocování výsledků naší sítě. Během dalších experimentů jsme narazili na časové omezení 24 hodin, a proto jsme trénovali síť s různým počtem iterací. Provedli jsme experimenty s počtem iterací 24000, 30000 a 40000. Zaznamenali jsme, že hodnota IoU dosáhla svého vrcholu při 30000 iteracích. Na základě tohoto zjištění jsme dospěli k závěru, že při dalším zvýšení počtu iterací na 40000 by došlo k přetrénování neuronové sítě. Pokusili jsme se také využít všechny 3 barevné kanály dostupné v obrazech a přidali jsme kontextuální informace z předchozího a následujícího řezu. Avšak i přes tuto modifikaci jsme nedosáhli významně lepších hodnot IoU a přetrénování sítě nastávalo dříve. Na obrázku 2 jsou zobrazeny nejlepší hodnoty IoU s využitím a bez využití RGB kontextu. Tyto výsledky nám



**Obrázek 2:** Porovnání nejlepších hodnot IoU dosažených během trénování s využitím a bez využití RGB kontextu.

### 4 Závěr

Jako výsledek jsme došli k závěru, že kvůli považování 2D obrázků za samostatné kontexty neuronové sítě s architekturou Mask-RCNN nejsou vhodné pro aplikace v oblasti segmentace orgánů. Naše výsledky by mohly být vylepšeny trénováním na řezech, které přímo obsahují cílové orgány a jejich minimální okolní řezy, nebo s využitím informací od jiných orgánů.

#### Literatura

He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision* (pp. 2961-2969).

Honda, H. (2020). Digging into Detectron 2—part 1. the link <https://medium.com/@hirotoschwert/digging-into-detectron-2-47b2e794fabd>.